수수컴정 KOCOH 데이터 이해와 EDA 결과

5 주차 데이터 점검과 6 주차 베이스라인 준비 · 2026 년 10 월 12 일

우리 팀은 **게시글 맥락을 함께 주면 한국어 혐오표현 탐지 성능이 개선되는가**를 연구한다. 이 문서는 팀원이 연구 질문, 데이터의 구성, 기존 논문과 우리 실험의 차이, EDA 결과와 처리 이유를 함께 이해하기 위한 자료다.

현재 KOCOH v2 의 3,000 행을 점검하고 다음 실험에 재사용할 입력과 분할을 준비했다. 원본 행을 삭제하거나 텍스트를 수정하지 않았다. **모델 학습·성능 평가는 아직 하지 않았으므로 맥락 추가의 효과는 미검증이다.**

1 이번 주에 준비할 범위

EDA 는 데이터를 탐색하여 구조·분포·결측·반복을 이해하고, 이후 처리와 실험 설계의 근거를 만드는 과정이다. 교수님은 에이전트에게 계산을 시켜도 숫자는 직접 읽고 판단하도록 안내한다. [수업 W5 90 쪽]

교수님이 요구한 작업	남겨야 할 결과	강의 쪽
데이터를 열고 크기·결측·범위·예측 대상 비율 확인	숫자 표와 팀 Notion 기록	90~94, 97
결측과 클래스 비율 시각화	figures/의 그림 2 장	90, 97
train/valid/test 규칙과 seed 고정	규약 파일과 분할 코드	95~96
전처리를 실행 가능한 파일로 정리	src/preprocess.py 실행 및 커밋	96~98
커밋 전 자동 점검과 실험 기록	작동하는 pre-commit hook, 실험로그 한 행	97

자료에는 **별도 제출은 없다**고 적혀 있다. 다만 위 결과는 팀 공간에 남겨야 한다. 목적은 같은 전처리를 6 주차 베이스라인과 7 주차 보고서에서 재현하는 것이다. 이번 단계에 모델 성능 결과까지 요구한 것은 아니다.

근거를 읽는 방법

- **팀 확정:** 원래 문제정의서와 데이터수집계획서의 연구 질문·데이터·비교 방향.
- **논문 설명:** KOCOH 제작자가 제시한 데이터 제작과 평가 방법.
- **실제 결과:** 고정한 CSV 와 이번 코드 실행에서 얻은 숫자.
- **현재 구현:** 연구 방향에 맞춰 에이전트가 구체화한 분할·입력 규칙.
- **미정:** 아직 선택하지 않은 모델·학습 방식·성공 기준.

2 우리가 풀 문제와 데이터 한 행의 의미

모델의 과제와 팀의 연구 질문

모델의 과제는 **주어진 게시글 맥락에서 댓글을 비혐오 0 또는 혐오 1 로 분류하는 것**이다. 정답 범주가 둘이므로 이진 분류라고 한다.

팀의 연구 질문은 다음과 같다. [문제정의서 §1]

> 댓글만으로는 판단하기 어려운 한국어 맥락 의존적 혐오표현에서, 게시글 맥락을 함께 활용하면 혐오표현 탐지 성능을 개선할 수 있는가?

여기에 전통적 텍스트 분류 방법과 사전학습 언어모델이 맥락을 활용하는 데 어떤 차이를 보이는지 비교한다는 계획이 있다.

KOCOH 를 한 문장으로 설명하면

KOCOH v2 는 한국어 게시글 맥락과 댓글을 한 쌍으로 묶고, 그 맥락에서 댓글이 혐오인지 아닌지 정답을 붙인 텍스트 데이터셋이다. 총 3,000 쌍이며, 맥락 의존적 혐오표현을 탐지하는 능력을 평가하도록 만들어졌다.

이미지 분류 데이터가 이미지와 클래스 라벨을 대응시키듯, 여기서는 **맥락–댓글 쌍과 혐오 여부 라벨**이 대응한다. 3,000 행은 서로 다른 게시글 3,000 개라는 뜻이 아니다. 같은 댓글이나 같은 맥락이 반복될 수 있다.

역할	CSV 열	의미
입력 텍스트	Context, Comment	게시글 요약 또는 대체 맥락, 댓글
예측할 정답	Hate speech	비혐오 0 / 혐오 1
식별·제작 정보	Index, Set, Type	행 번호, 게시글 그룹 번호, 제작 유형
출처 정보	Date, Source, Link, Title	날짜, 커뮤니티, 링크, 제목
추가 주석 8 개	Counter speech, Gender, Disability, Race/Nationality, Region (Korea), Age, Profanity, Ikiyano-style	대응 발언·대상 집단·욕설·문체 정보

실제 CSV 는 **3,000 행·18 열·101 개 Set** 이다. Set 은 게시글 그룹 식별자이며 공식 train/test 구분이 아니다. Context 는 게시글 전문이 아니라 요약 또는 사람이 만든 대체 맥락이다.

주된 정답은 Hate speech 한 열이다. 대상 집단 주석을 여러 클래스로 분류하는 문제로 바꾼 것은 아니다. 논문은 전문가 3 명이 모두 동의한 사례를 남겼다고 설명하며, 이번 EDA 에서 정답을 새로 붙이지 않았다.

3 같은 댓글도 맥락에 따라 정답이 달라진다

다음은 실제 CSV 의 Index 8 과 36 이다. 두 댓글의 글자는 같지만 맥락과 정답이 다르다.

구분	Context	Comment	정답
Index 8	여성 고용이 미흡해 정부가 불이익을 준 기업의 이름이 공개되었다.	믿을 만한 그룹이라는 얘기네	혐오 1
Index 36	직원에게 높은 수준의 복지를 제공한 기업의 이름이 공개되었다.	믿을 만한 그룹이라는 얘기네	비혐오 0

첫 번째는 여성 고용이 미흡한 기업을 긍정하는 의미로, 두 번째는 좋은 직원 복지를 긍정하는 의미로 주석되었다. 정답은 댓글 문자열만의 속성이 아니라 **맥락과 댓글 조합에 대한 판단**이다.

세 제작 유형

유형	제작 방식	라벨	행 수
Type 1	실제 맥락 A + 해당 글의 혐오 댓글 C	1	764
Type 2	사람이 만든 맥락 B + 같은 댓글 C	0	764
Type 3	실제 맥락 A + 다른 비혐오 댓글 D	0	1,472

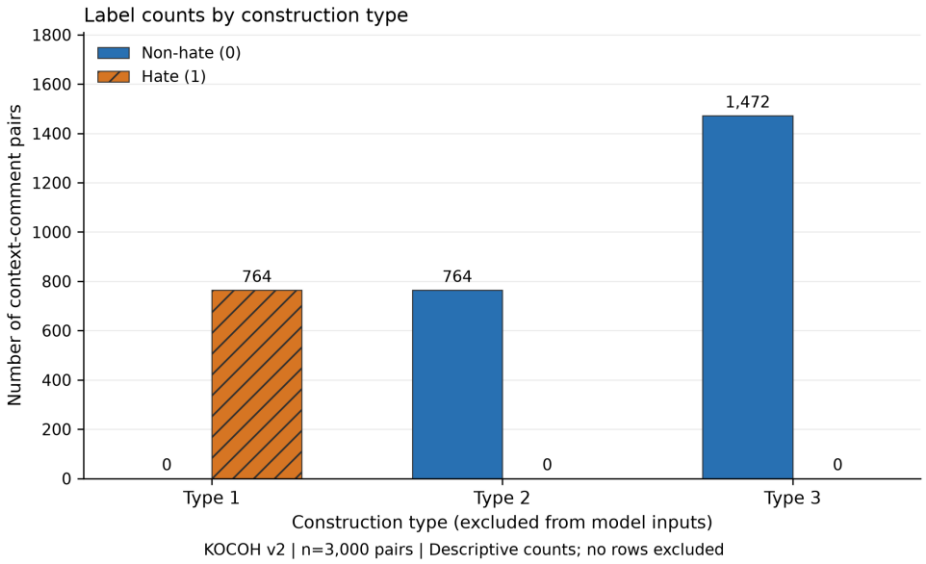


그림 1. 전체 3,000 쌍의 제작 유형별 라벨 개수. 제외한 행은 없다.

Type 1·2 는 같은 댓글에 대한 맥락 차이를, Type 1·3 은 같은 맥락에 대한 댓글 차이를 보여준다. **Type 은 정답과 직접 연결되므로 모델 입력에 넣지 않는다.** 댓글만 기준으로 중복을 제거하면 맥락에 따른 비교 사례를 잃을 수 있다.

4 기존 논문과 우리 팀의 데이터 사용 방법

원논문의 zero-shot 평가

KOCOH 논문 §4.1 은 이미 학습된 언어모델에 과제 설명·혐오 정의·맥락·댓글을 주고 0 또는 1 을 출력하도록 한다. **정답이 붙은 시범 예시를 프롬프트에 넣지 않는 zero-shot 설정**이며, KOCOH 로 모델 가중치를 추가 학습하는 절차를 제시하지 않는다. 예측한 뒤 정답과 비교해 평가한다.

Zero-shot 은 학습하지 않은 모델이라는 뜻이 아니다. 이미 사전학습된 모델을 사용하며, 이 과제의 정답 예시를 주어 추가 학습하는 단계 없이 평가한다. 정답 라벨은 여전히 채점에 필요하다.

팀 문서에 있는 방향과 아직 정하지 않은 것

문제정의서 §2 에는 전통적 분류 방법과 사전학습 언어모델 각각에서 댓글만 입력하는 조건과 맥락을 함께 입력하는 조건을 비교한다고 적혀 있다. §4 에는 '직접 학습하는 모델'과 자원 제약을 고려한 모델 선정이 언급되어 있다.

직접 학습하는 비교를 준비할 근거는 팀 문서에 있다. 다만 모든 조건의 구체적인 지도학습 방식을 확정한 것은 아니다. 현재의 분할과 입력 준비는 이 방향에 맞춘 에이전트 구현이다. 지도학습은 입력과 정답을 이용해 예측 규칙을 학습하는 방식이다.

비교할 모델 계열	댓글만	맥락 + 댓글
전통적 텍스트 분류 방법	실험 A	실험 B
사전학습 언어모델 활용 방법	실험 C	실험 D

예를 들어 TF-IDF 로 텍스트를 숫자로 바꾸고 Logistic Regression 을 학습하는 방법은 깊은 신경망 없이 가능하다. BERT 계열은 신경망으로 텍스트 표현을 만든 뒤 분류층을 연결할 수 있다. **두 설명은 구현 예시이며 최종 모델 선정이 아니다.**

신경망을 쓴다면 '텍스트 → 토큰 번호 → 언어모델의 수치 표현 → 분류층 → 0/1 예측' 흐름이다. train 의 정답과 예측의 차이를 줄이도록 가중치를 조정한다. 언어모델 본체를 고정하고 분류기만 학습할지, 본체도 fine-tuning 할지는 미정이다.

기존 Notion 에는 KcBERT·KcELECTRA 와 macro-F1 이 후보 메모로 남아 있다. 최종 모델과 주요 지표의 정의는 실험 전에 확인해야 한다. 이번에는 혐오 클래스 F1·정밀도·재현율과 정확도를 해석에 사용했으며 모델 점수는 계산하지 않았다.

원논문의 전체 자료 zero-shot 점수와 우리의 일부 자료 학습 후 test 점수는 조건이 다르다. 우선 **같은 test 안에서 B−A 와 D−C 의 성능 차이**로 맥락 추가 효과를 비교해야 한다.

5 EDA 결과와 처리 판단

5.1 결측은 얼마나 있고 왜 생겼는가

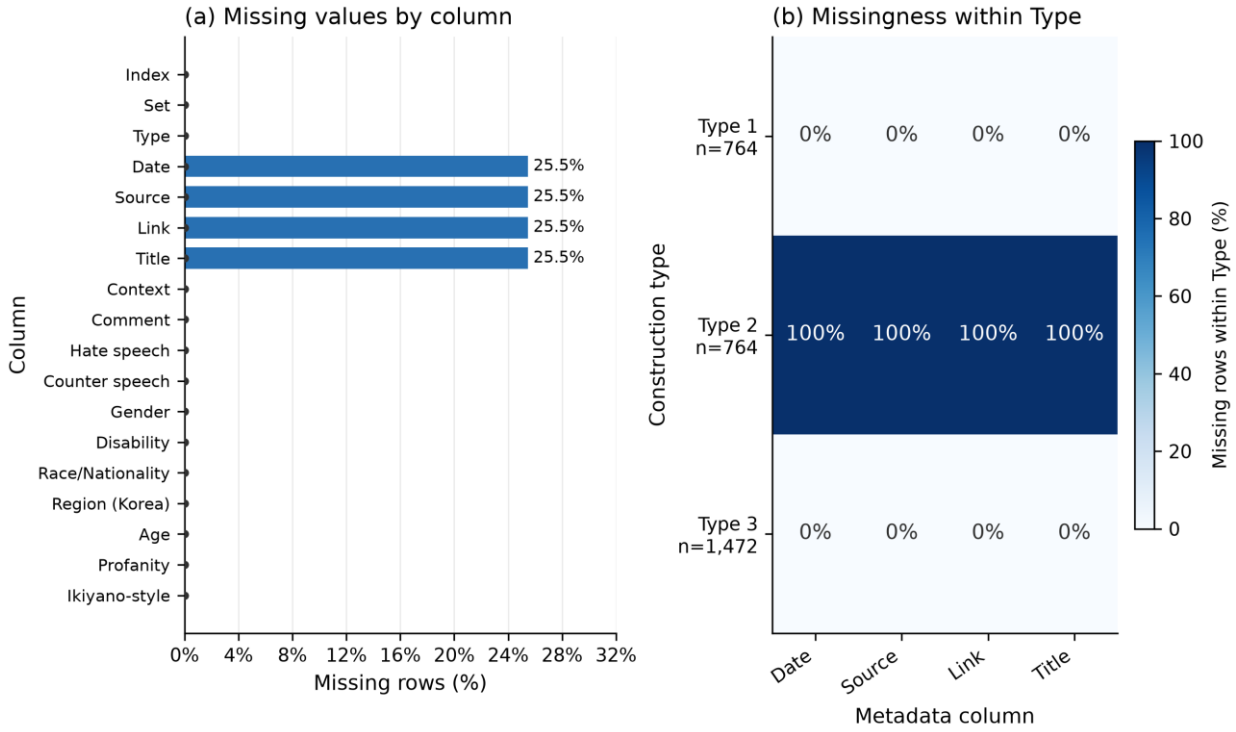


그림 2. 왼쪽은 전체 3,000 행, 오른쪽은 각 Type 내부의 행을 분모로 계산한 결측률이다. 전체 25.47%와 Type 2 내부 100%를 구별한다.

실제로 확인한 것	해석과 결정
Date·Source·Link·Title 각 764 건 결측	모두 Type 2 에 있다. 사람이 만든 대체 맥락의 출처 정보가 없는 구조와 연결된다.
Context·Comment·Hate speech 결측 0 건	실제 입력과 정답이 있으므로 출처 결측을 이유로 삭제하지 않는다.
전 열 공백 문자열 0 건	결측 표시 외의 빈 문자열도 확인했다.
삭제 0 행, 원문 수정 0 행	원본을 그대로 유지했다.

결측률 숫자만으로 삭제를 결정하지 않고, **어느 유형에 왜 생겼으며 분석에 필요한 정보가 남아 있는지** 확인했다.

원본 Source 는 디시인사이드 1,453 행, 에펨코리아 783 행, 미기재 764 행이다. Set 의 실제 출처를 대응시키는 별도 집계는 1,981 / 1,018 / 미확인 1 행이다. 원본 결측을 채워 넣은 것은 아니다. 논문 Table 4 의 1,982 / 1,018 과 다른 1 행을 임의로 배정하지 않았다.

5.2 길이와 반복 구조는 적절한가

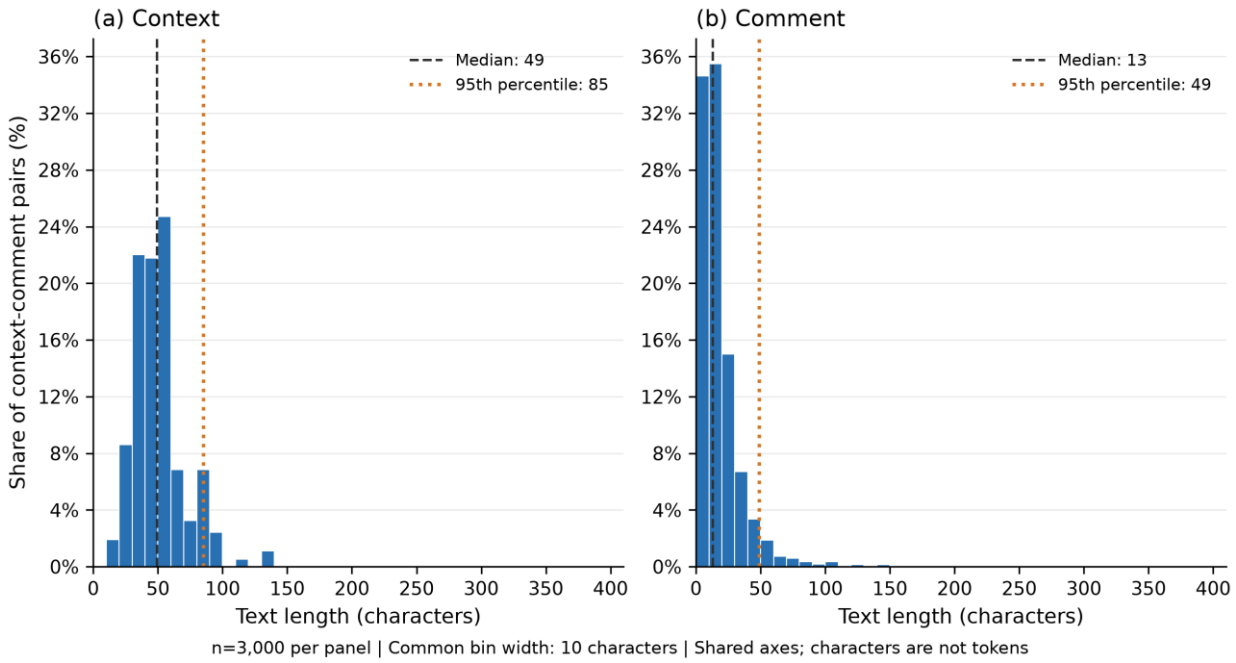


그림 3. 각 패널은 3,000 행이며, 10 문자 구간과 같은 축을 사용했다. 파선은 중앙값, 점선은 95 백분위다. 문자 수는 모델 토큰 수와 다르다.

문자 수	최솟값	중앙값	95 백분위	최댓값
Context	15	49	85	136
Comment	1	13	49	400

긴 댓글을 측정 오류로 단정하지 않고 유지했다. 실제 모델을 정하면 train/valid 에서 tokenizer 기준 입력 길이와 잘림 비율을 점검해야 한다. 이번에는 자르기·불용어 삭제·기호 제거를 적용하지 않았다. 날짜 범위는 2024-06-02~2025-01-21 이며 파싱 실패는 0 건이다.

반복 점검	결과와 판단
서로 다른 라벨을 갖는 같은 댓글	710 종. 맥락이 다르면 정답이 달라질 수 있어 댓글만 기준으로 제거하지 않는다.
동일한 Context–Comment 쌍	추가 중복 6 행. 같은 댓글만 반복되는 경우와 구분하여 기록했다.
동일한 두 입력에 서로 다른 라벨	0 그룹. 입력 쌍 자체의 라벨 충돌은 발견하지 못했다.
Index 를 제외한 전 열 동일 중복	1 행. 자동 제거하지 않고 평가 영향 검토 대상으로 남겼다.

'710 종'은 고유 댓글 문자열 개수이며 행 수가 아니다. 이 EDA 는 전체의 구조 점검이다. TF-IDF 의 어휘·IDF 나 대체값처럼 데이터에서 학습하는 변환은 분할 이후 train 에서만 학습한다.

5.3 클래스 불균형은 평가에 어떤 영향을 주는가

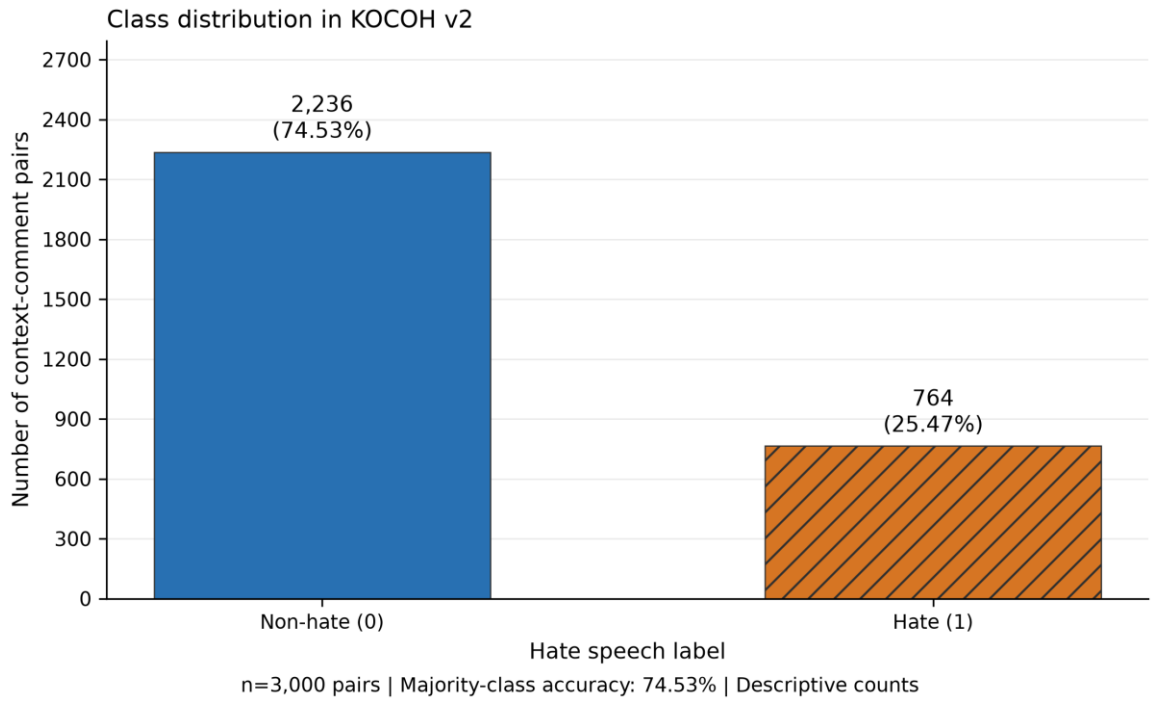


그림 4. 전체 3,000 쌍 중 비혐오 2,236 행, 혐오 764 행이다. 제외한 행은 없다.

모두 비혐오라고 답해도 전체 정확도는 2,236 / 3,000 = 74.53%다. 하지만 이때 혐오 사례는 전부 놓친다. 이 수치는 학습한 모델의 성과가 아니라 데이터 구성에서 나오는 기준선이다.

지표	이 연구에서 확인할 것
혐오 정밀도 Precision	혐오라고 예측한 것 중 실제 혐오의 비율
혐오 재현율 Recall	실제 혐오 중 찾아낸 비율
혐오 F1	혐오 정밀도와 재현율의 조화평균
정확도 Accuracy	전체 중 맞힌 비율. 해당 평가 분할의 기준선과 함께 해석
macro-F1	두 클래스의 F1 을 같은 비중으로 평균. 기존 팀 Notion 의 후보 지표

혐오 F1 과 macro-F1 은 같은 값이 아니다. 팀 문서에는 F1·Recall 이 언급되고 Notion 에는 macro-F1 메모가 있으므로, **주요 비교 지표와 성공 기준을 실제 실험 전에 명시**해야 한다.

전부 비혐오 예측이면 혐오 재현율은 0 이다. 양성 예측이 없어 혐오 정밀도는 정의되지 않으며 계산에서는 0 으로 처리할 수 있다. 이때 혐오 F1 도 0 으로 보고한다. 74.53%는 전체 자료 기준이며 최종 평가는 test 자체의 기준선과 비교해야 한다.

이 데이터는 맥락 의존 사례를 골라 제작했으므로 혐오 비율을 온라인 댓글 전체의 비율로 일반화할 수 없다. 논문 §3.3 의 혐오 886 건은 Table 4·공개 CSV 의 764 건과 다르며, 이번에는 버전을 고정한 CSV 실측값을 사용했다.

6 다음 실험을 위한 입력과 분할

입력을 제한하는 이유

댓글 조건에는 Comment, 맥락 조건에는 Context 와 Comment 만 입력한다. 정답 Hate speech 는 별도로 반환한다. Type·식별자·추가 정답 주석·출처를 학습기에 통째로 넣지 않는다. 특히 Type 은 정답을 직접 드러내므로 텍스트 분류 능력을 평가할 수 없게 만든다.

현재 고정한 분할

현재 구현: 원본 행 순서를 유지하여 StratifiedGroupKFold(5, shuffle=True, random_state=42)를 적용했다. 그룹은 Set, 비율을 고려할 대상은 Hate speech 다. fold 0 은 test, fold 1 은 valid, 나머지는 train 이다.

분할	목적	행 수	Set 수	비혐오	혐오
train	정답으로 예측 규칙 학습	1,770	61	1,325	445
valid	모델·설정 선택	639	21	471	168
test	선택이 끝난 방법의 최종 평가	591	19	440	151

같은 게시글 그룹이 학습과 시험 양쪽에 들어가지 않도록 Set 을 묶었다. 분할 간 Set 중복은 0 이며 그룹 크기가 달라 정확한 60/20/20 은 아니다. 분할법과 seed 는 원래 두 팀 문서에 없는 구체적 구현이다. 원논문의 공식 분할로 부르지 않는다.

남아 있는 한계

비교	같은 Context	같은 Comment	같은 두 입력 쌍
train / valid	9 종	14 종	1 쌍
train / test	4 종	12 종	2 쌍
valid / test	6 종	11 종	3 쌍

표는 양쪽에 공통인 고유 값의 개수다. **Set 분할이 모든 반복 텍스트를 제거하지는 않는다.** Index 1500(Type 1, Set 43, train)과 1501(Type 2, Set 44, test)은 댓글이 같지만 Set 이 다른 예외다. 원본 번호를 고치지 않고 따로 기록했다.

학습 전에 반복 입력과 이 예외의 평가 방침을 검토한다. 성능을 보고 seed 를 고르거나 test 에 맞춰 처리를 바꾸지 않는다. 모든 모델·입력 조건은 같은 분할을 재사용하고, 학습되는 전처리는 train 에서만 fit 한다.

7 현재 결론과 다음 할 일

지금 설명할 수 있는 결론

우리는 KOCOH 가 맥락–댓글 쌍을 분류하는 데이터임을 확인했다. Type 2 의 출처 결측과 동일 댓글의 다른 라벨은 제작 구조와 연결되므로 원본을 유지했다. 불균형 때문에 정확도만으로 판단하기 어렵고, 분할은 Set 을 묶어 준비했지만 반복 입력의 한계가 남아 있다. **맥락 추가가 성능을 높이는지는 아직 확인하지 않았다.**

베이스라인 전에 확인할 사항

다음 확인	이유
모델 후보와 학습 방식 선택	전통적 방법과 사전학습 모델을 자원 상한 안에서 비교하기 위해
tokenizer 기준 길이·잘림 확인	맥락을 추가하면서 댓글이 잘리는 영향을 구분하기 위해
반복 입력·Set 예외의 평가 방침	어떤 독립성을 가진 시험인지 분명히 하기 위해
주요 지표·성공 기준·반복 조건 명시	혐오 F1 과 macro-F1 을 혼동하거나 결과를 보고 기준을 고르지 않기 위해
같은 분할에서 두 입력 조건 실행	맥락 추가 효과를 공정하게 비교하기 위해

자료를 찾는 순서

- **팀 공유와 실험 기록:** 팀 Notion.
- **코드와 재현 결과:** 팀 GitHub. 실행 순서는 저장소 README 에 있다.
- **근거 문서:** 문제정의서가 있는 팀 페이지, 데이터수집계획서가 있는 팀 페이지.
- **실제 결과:** results/의 요약·표, figures/의 그림, notebooks/w5_eda_자동화.ipynb 의 실행 출력.

출처와 적용 범위

1. W5_GPT_BERT_v5.pdf 90~98 쪽: EDA 작업·산출물, 누수 방지, 다음 주 베이스라인 준비. 팀의 수업자료를 참고한다.

2. 문제정의서(2026-09-19)와 데이터수집계획서(2026-09-22): 연구 질문과 데이터 선택. 기존 Notion 의 후보 메모는 확정 내용과 구분했다.

3. Park & Song, KOCOH, LREC 2026: §3 제작·주석, Table 4 구성, §4.1 zero-shot 평가.

4. KOCOH 공식 배포, GitHub: Hugging Face CC BY-NC 4.0 을 이용 근거로 삼고 데이터와 논문을 인용한다. GitHub 의 TBD 표기 차이는 남아 있다.

5. 사용 CSV revision: c26d8e86f3d7a9a6dcd4e308cb747b6bc6427d6f. SHA256·다운로드 방법은 data/README.md 에 기록했다. 원본은 저장소에 올리지 않고 같은 버전을 내려받는다.

이 문서의 해석은 현재 데이터와 준비한 실험 범위에 한정된다. 실제 모델 선정과 평가 결과에 따라 이후 설명을 보완한다.